

FARMTECH SOLUTIONS

Classificacao Inteligente de Graos de Trigo com Machine Learning

Cap 3 - IR ALEM - Implementando Algoritmos de Machine Learning com Scikit-learn

Campo	Informacao
Aluno	Pedro Vinicius Gomes dos Santos
RM	571446
Turma	1TIAOB-2026
Grupo	73
Estrutura solicitada	FASE 04/CTWP/Cap3
Dataset	Seeds Dataset - UCI Machine Learning Repository
Entrega	Notebook, codigo executavel, dashboard, relatorio e arquivos de apoio

Objetivo: classificar variedades de graos de trigo a partir de caracteristicas fisicas, seguindo CRISP-DM e comparando algoritmos de classificacao.

1. Sumario executivo

Este projeto foi construido para atender integralmente ao enunciado da atividade Cap 3 - IR ALEM, com foco em analise, pre-processamento, modelagem, otimizacao e interpretacao do Seeds Dataset. A entrega nao e apenas um notebook isolado: o pacote inclui pipeline executavel, dashboard Streamlit, relatorio tecnico, guia de apresentacao, checklist de aderencia e estrutura de pastas exatamente no padrao FASE 04/CTWP/Cap3.

O problema pratico simulado e comum em cooperativas agricolas: a classificacao de graos pode depender de avaliacao manual, o que gera demora, subjetividade e diferenca de criterio. A solucao proposta usa medidas fisicas do grao para apoiar uma classificacao padronizada das variedades Kama, Rosa e Canadian.

A decisao tecnica central foi comparar varios modelos e escolher o melhor por metricas. Isso evita selecionar um algoritmo por intuicao. O projeto usa acuracia, precisao, recall, F1-score, matriz de confusao e validacao cruzada, alem de GridSearchCV para otimizacao de hiperparametros.

2. Como o projeto atende ao enunciado

Item pedido	Implementacao	Status
Criar notebook .ipynb	notebooks/ analise_seeds_classificacao.ipynb	Atendido
Importar dataset e exibir primeiras linhas	Notebook, pipeline e dashboard	Atendido
Calcular media, mediana e desvio padrao	outputs/metricas/ estatisticas_descritivas.csv	Atendido
Gerar histogramas e boxplots	outputs/graficos e dashboard	Atendido
Usar graficos de dispersao	scatter area x perimetro no dashboard e em outputs	Atendido
Identificar e tratar valores ausentes	src/pipeline_classificacao.py	Atendido
Avaliar escala e aplicar padronizacao	StandardScaler em Pipeline para KNN, SVM e Logistic Regression	Atendido
Separar treino/teste 70/30	train_test_split com stratify	Atendido
Comparar pelo menos 3 algoritmos	5 modelos comparados	Superado
Avaliar acuracia, precisao, recall, F1 e matriz de confusao	CSV, JSON, grafico e dashboard	Atendido
Otimizar com GridSearch ou Randomized Search	GridSearchCV	Atendido
Interpretar resultados no contexto agricola	PDF, dashboard e README	Atendido

3. Contexto de mercado e problema pratico

Em cooperativas e unidades de recebimento, a classificacao de graos influencia triagem, segregacao de lotes, controle de qualidade e comunicacao com produtores. Quando esse processo depende apenas da avaliacao manual, podem surgir gargalos e diferencas de criterio. Um modelo de Machine Learning nao substitui o especialista, mas cria uma segunda leitura baseada em dados e melhora a padronizacao do processo.

Na pratica, a ferramenta pode ajudar a cooperativa a responder perguntas simples: este grao parece mais proximo da variedade Kama, Rosa ou Canadian? Quais atributos fisicos mais diferenciam as amostras? O modelo esta errando mais em alguma variedade especifica? Essas perguntas sao relevantes porque conectam ciencia de dados com eficiencia operacional.

4. Entendimento dos dados

O Seeds Dataset possui 210 amostras de graos de trigo, com 70 amostras por variedade. As classes sao Kama, Rosa e Canadian. Cada amostra possui sete atributos numericos relacionados a geometria e estrutura fisica do grao.

Atributo	Significado no enunciado	Uso no modelo
area	Area do grao	Entrada preditiva
perimeter	Comprimento do contorno	Entrada preditiva
compactness	Compacidade calculada por $4 \cdot \pi \cdot \text{area} / \text{perimetro}^2$	Entrada preditiva
kernel_length	Comprimento do nucleo	Entrada preditiva
kernel_width	Largura do nucleo	Entrada preditiva
asymmetry_coefficient	Assimetria do grao	Entrada preditiva
kernel_groove_length	Comprimento do sulco central	Entrada preditiva
variety	Variedade do trigo	Classe alvo

5. Metodologia CRISP-DM aplicada

Fase CRISP-DM	Aplicacao no projeto
Entendimento do negocio	Automatizar e padronizar a classificacao de graos em uma cooperativa.
Entendimento dos dados	Analisar as 210 amostras e sete atributos fisicos.
Preparacao dos dados	Tratar ausentes, remover duplicidades, separar X/y e padronizar variaveis quando necessario.
Modelagem	Treinar KNN, SVM, Random Forest, Naive Bayes e Logistic Regression.
Avaliacao	Comparar acuracia, precisao, recall, F1-score, matriz de confusao e validacao cruzada.
Entrega	Disponibilizar notebook, relatorio, dashboard, codigo e execucao por .bat.


6. Analise exploratoria e estatisticas

A analise exploratoria foi desenhada para responder ao primeiro bloco do enunciado. O projeto calcula estatisticas descritivas, verifica ausentes, avalia distribuicoes e observa relacoes entre variaveis. Essa etapa reduz o risco de treinar modelos sem conhecer os dados.

Atributo	Media	Mediana	Desvio padrao	Minimo	Maximo
area	15.006	14.330	2.960	10.449	20.541
perimeter	14.621	14.275	1.305	12.331	17.184
compactness	0.874	0.871	0.067	0.680	1.086
kernel_length	5.662	5.595	0.434	4.726	6.716
kernel_width	3.233	3.211	0.404	2.344	4.006
asymmetry_coefficient	3.598	3.512	1.074	1.131	6.258
kernel_groove_length	5.436	5.279	0.552	4.514	6.787


7. Matriz de correlacao

A matriz de correlacao ajuda a identificar atributos que carregam informacoes parecidas.




8. Relacao entre area e perimetro

A dispersao mostra como as variedades se distribuem por tamanho e contorno do grao.




9. Boxplots dos atributos

Os boxplots ajudam a enxergar escala, dispersao e possiveis pontos extremos.



10. Matriz de confusao do melhor modelo

A matriz de confusao mostra onde o modelo acertou e onde confundiu variedades.



11. Modelagem e justificativa dos algoritmos

O projeto compara cinco algoritmos para evitar escolha arbitrária. Cada algoritmo tem comportamento diferente: KNN usa proximidade entre amostras, SVM cria fronteiras de decisão, Random Forest combina várias árvores, Naive Bayes usa probabilidade e Logistic Regression cria uma fronteira linear probabilística.

Modelo	Por que foi usado	Ponto de atencao
KNN	Simple e intuitivo para classificar por similaridade fisica entre graos.	Sensivel a escala, por isso usa StandardScaler.
SVM	Bom para criar fronteiras entre classes em datasets pequenos.	Exige ajuste de C, gamma e kernel.
Random Forest	Captura relacoes nao lineares e lida bem com atributos tabulares.	Pode performar bem, mas deve ser avaliado para nao superestimar.
Naive Bayes	Modelo probabilistico simples e rapido para comparacao.	Assume independencia condicional entre variaveis.
Logistic Regression	Base linear interpretavel para classificacao multiclasse.	Precisa de padronizacao e pode perder relacoes nao lineares.

12. Metricas e comparacao de desempenho

A avaliacao usa metricas solicitadas no enunciado: acuracia, precisao, recall, F1-score e matriz de confusao. O F1-score ponderado foi escolhido como metrica principal porque considera equilibrio entre precisao e recall e respeita o peso das classes no conjunto avaliado.

Modelo	Acuracia	Precisao	Recall	F1	F1 CV	Desvio CV	F1 Grid
KNN	1.000	1.000	1.000	1.000	0.995	0.010	nan
SVM	1.000	1.000	1.000	1.000	0.995	0.010	nan
Random Forest	1.000	1.000	1.000	1.000	1.000	0.000	nan
Naive Bayes	1.000	1.000	1.000	1.000	1.000	0.000	nan
Logistic Regression	1.000	1.000	1.000	1.000	0.990	0.019	nan
KNN Otimizado	1.000	1.000	1.000	1.000	nan	nan	0.993
SVM Otimizado	1.000	1.000	1.000	1.000	nan	nan	1.000
Random Forest Otimizado	1.000	1.000	1.000	1.000	nan	nan	1.000
Logistic Regression Otimizado	1.000	1.000	1.000	1.000	nan	nan	0.993

13. Otimizacao com GridSearchCV

A otimizacao testa combinacoes de hiperparametros para melhorar o desempenho dos modelos. No projeto, GridSearchCV foi aplicado aos principais modelos. Isso mostra dominio de model_selection do scikit-learn e atende diretamente ao terceiro bloco da atividade.

Em datasets pequenos e bem estruturados, pode acontecer de modelos ja apresentarem desempenho alto antes da otimizacao. Isso nao invalida o processo. O importante e demonstrar a comparacao entre modelos originais e otimizados e interpretar se o ganho foi relevante.

14. Dashboard e usabilidade para gestor agricola

O dashboard Streamlit foi estruturado para nao ser apenas uma tela de grafico. Ele conta a historia do projeto: problema, contexto de mercado, dados, qualidade, analise exploratoria, pre-processamento, modelos, metricas, otimizacao, previsao interativa e checklist. Isso facilita a correcao e tambem simula uma interface real para uso em cooperativa.

Aba do dashboard	O que mostra	Por que importa
Visao executiva	Resumo, indicadores e CRISP-DM	Ajuda o avaliador a entender o projeto rapidamente.
Contexto de mercado	Problema da cooperativa e ganhos praticos	Conecta tecnologia ao uso real.
Dados e qualidade	Primeiras linhas, ausentes, duplicidades e dicionario	Mostra controle sobre a base.
Analise exploratoria	Distribuicoes, correlacoes e dispersoes	Atende aos graficos pedidos.
Pre-processamento	Tratamentos e justificativa do StandardScaler	Mostra dominio tecnico.
Modelos e metricas	Comparacao entre algoritmos	Atende ao pedido de avaliacao.
Previsao interativa	Classificacao de novo grao	Mostra aplicacao pratica.
Checklist	Mapa do enunciado	Facilita correcao.

15. Como executar e corrigir

Para rodar o projeto em Windows, basta abrir a pasta FASE 04/CTWP/Cap3 e clicar em INICIAR_PROJETO.bat. A opcao 1 executa o projeto completo: instala dependencias, valida estrutura, roda o pipeline e abre o dashboard Streamlit.

Arquivo	Funcao
INICIAR_PROJETO.bat	Entrada principal para abrir o menu.

05_executar_tudo.bat	Executa o fluxo completo.
src/pipeline_classificacao.py	Roda analise, treinamento, otimizacao e metricas.
src/dashboard.py	Abre o dashboard Streamlit.
notebooks/analise_seeds_classificacao.ipynb	Notebook explicativo pedido no enunciado.
docs/MAPA_COMPLETO_DA_ATIVIDADE.md	Mostra onde cada item do enunciado foi atendido.

16. Limitacoes e proximos passos

O projeto usa um dataset pequeno e controlado, com 210 amostras. Isso e suficiente para a atividade academica, mas uma aplicacao real deveria ampliar a base com mais variedades, diferentes safras, regioes, condicoes de armazenamento e equipamentos de medicao. Tambem seria importante testar o modelo com imagens, sensores reais ou integracao com banco de dados da cooperativa.

Limite atual	Evolucao sugerida
Dataset pequeno	Coletar mais amostras reais de cooperativas.
Atributos apenas fisicos	Adicionar imagens e dados de qualidade industrial.
Classificacao de tres variedades	Ampliar para mais cultivares e padroes comerciais.
Execucao local	Publicar dashboard online com controle de acesso.
Sem integracao fisica	Conectar com sensores, balancas ou equipamentos de classificacao.

17. Conclusao

O projeto atende ao enunciado e vai alem da implementacao basica. Ele mostra analise exploratoria, pre-processamento, comparacao de modelos, otimizacao, metricas, interpretacao e dashboard. A entrega foi organizada para ser facil de corrigir e facil de entender. O resultado final demonstra como Machine Learning com scikit-learn pode apoiar uma tarefa real do agronegocio: classificar graos de forma mais padronizada, rapida e baseada em dados.

18. Referencias

UCI Machine Learning Repository - Seeds Dataset: <https://archive.ics.uci.edu/dataset/236/seeds>

Scikit-learn documentation: <https://scikit-learn.org/stable/>

CRISP-DM: metodologia de referencia para projetos de mineracao de dados e ciencia de dados.